Санкт-Петербургский Политехнический Университет
Высшая школа прикладной математики и вычислительной физики, ФизМех
01.03.02 Прикладная математика и информатика

Отчет по лабораторной работе № 3
"Боксплот Тьюки и анализ выбросов"

Выполнил студент гр. 5030102/30201 Елисеева М. А.
Преподаватель Баженов А. Н.

Санкт-Петербург
2025

Постановка задачи

Задание:
1. Сгенерировать выборки объёмом n = 20,100. Построить боксплот Тьюки.
2. Определить долю выбросов экспериментально: для каждого распределения сгенерировать 1000 выборок заданного объёма, вычислить среднюю долю выбросов.

Цели и задачи:
Научиться применять боксплот Тьюки в обработке и анализе одномерных распределений.
Проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значений.

Исследуются следующие распределения:
1. Нормальное $N(x;0,1)$
2. Коши $C(x;0,1)$
3. Лапласа $L(x;0, 1/\sqrt{2})$
4. Пуассона $P(k;10)$
5. Равномерное $U(x;-\sqrt{3},\sqrt{3})$

Теоретическая часть

- Нормальное распределение

$$Normal(x, 0{,}1) = \frac{1}{\sqrt{2\pi}} e^{\frac{-x^2}{2}}$$

- Распределение Коши

$$Cauchy(x, 0{,}1) = \frac{1}{\pi} \frac{1}{x^2 + 1}$$

- Распределение Лапласса

$$Laplace\left(x, 0, \frac{1}{\sqrt{2}}\right) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}$$

- Распределение Пуассона

$$Poisson(k, 10) = \frac{10^k}{k!} e^{-10}$$

- Равномерное распределение

$$Uniform\left(x, -\sqrt{3}, \sqrt{3}\right) = \begin{cases} \frac{1}{2\sqrt{3}} \text{ при } |x| \leq \sqrt{3} \\ 0 \text{ при } |x| > \sqrt{3} \end{cases}$$

Боксплот Тьюки — графическое представление одномерного распределения, отображающее медиану, квартили и выбросы. Прямоугольник («ящик») ограничен первым (Q_1) и третьим (Q_3) квартилями; линия внутри ящика — медиана (Q_2). От ящика отходят «усы» до минимального и максимального наблюдений, не являющихся выбросами. Границы усов определяются как

$$\text{нижняя граница} = Q_1 - 1.5 \cdot IQR, \text{ верхняя граница} = Q_3 + 1.5 \cdot IQR,$$

где $IQR = Q_3 - Q_1$ — межквартильный размах. Наблюдения за пределами этих границ считаются выбросами и отмечаются точками. Боксплот позволяет оценить центр, разброс, асимметрию и наличие аномальных значений в данных.

Вычисление квартилей

- Упорядочивание выборки по возрастанию.
- Q_1 (первый квартиль) – значение, ниже которого лежат 25% данных.
- Q_3 (третий квартиль) – значение, ниже которого лежат 75% данных.
- Q_2 (медиана) – значение, делящее выборку пополам.

Реализация

Язык программирования: Python 3.12

Сторонние библиотеки:
numpy – генерация случайных выборок
matplotlib.pyplot – построение графиков

Код: https://github.com/MaryEliseeva/matstat/blob/main/lab3/lab3.py

Результаты

Распределение	n	Средняя доля выбросов	Стандартное отклонение
Нормальное	20	2.29%	4.12%
Нормальное	100	1.01%	1.27%
Коши	20	15.07%	7.06%
Коши	100	15.56%	3.35%
Лапласа	20	7.31%	6.54%
Лапласа	100	6.55%	3.09%
Пуассона	20	2.62%	5.19%
Пуассона	100	1.33%	1.64%
Равномерное	20	0.23%	1.52%
Равномерное	100	0.00%	0.00%

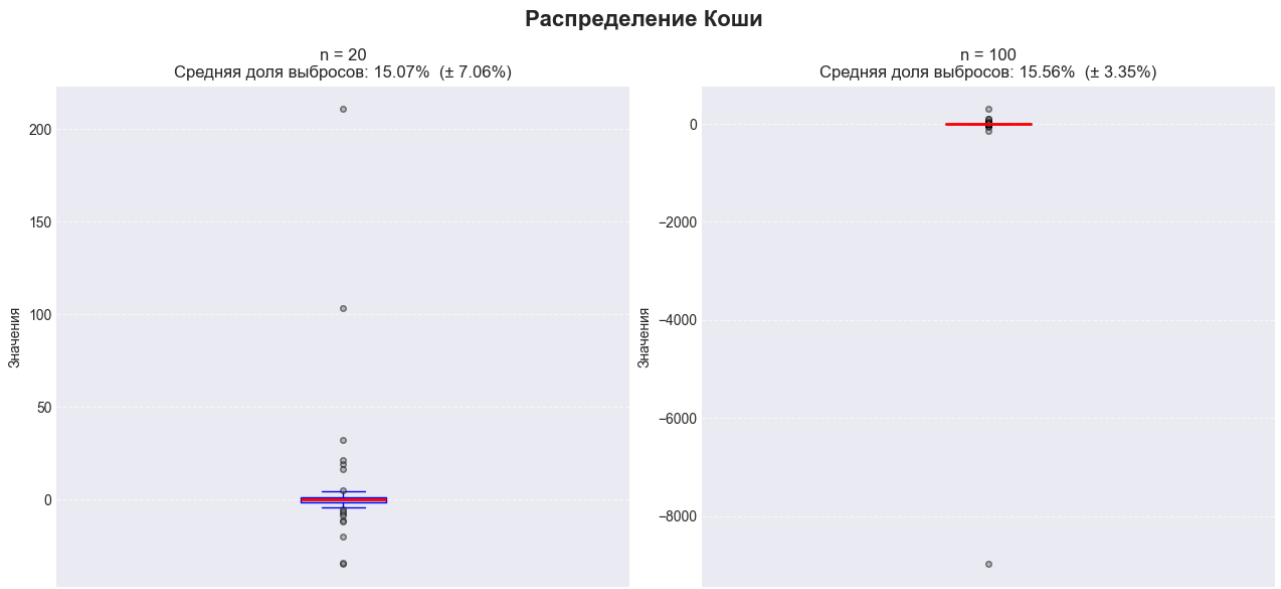

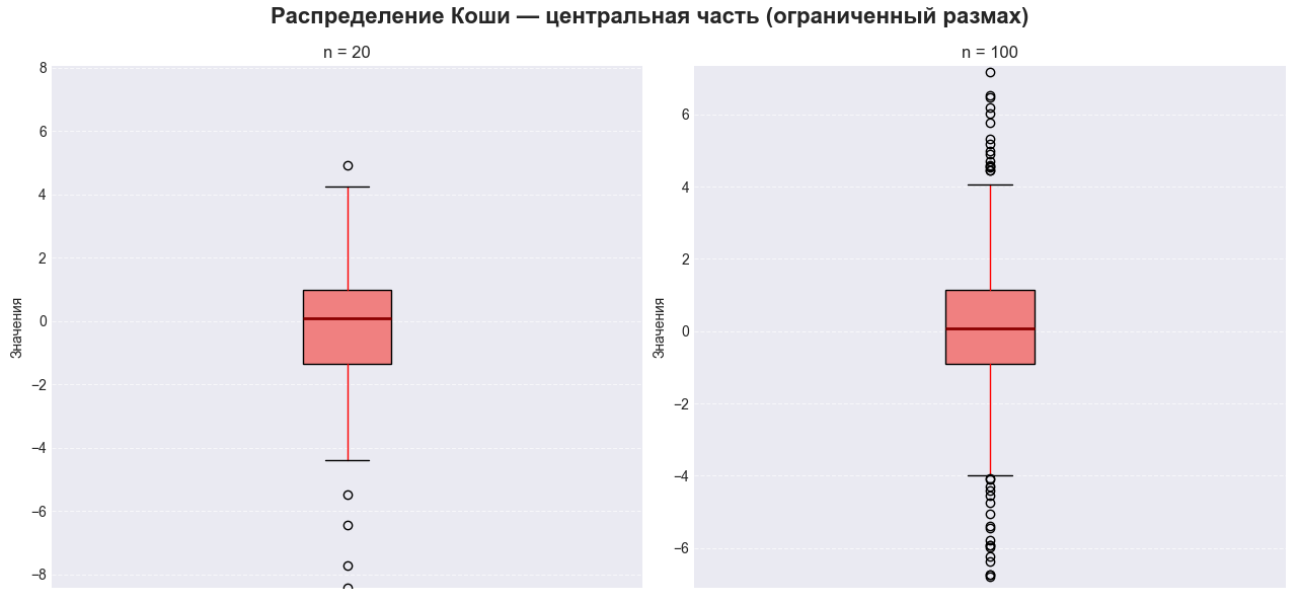

Распределение Лапласа

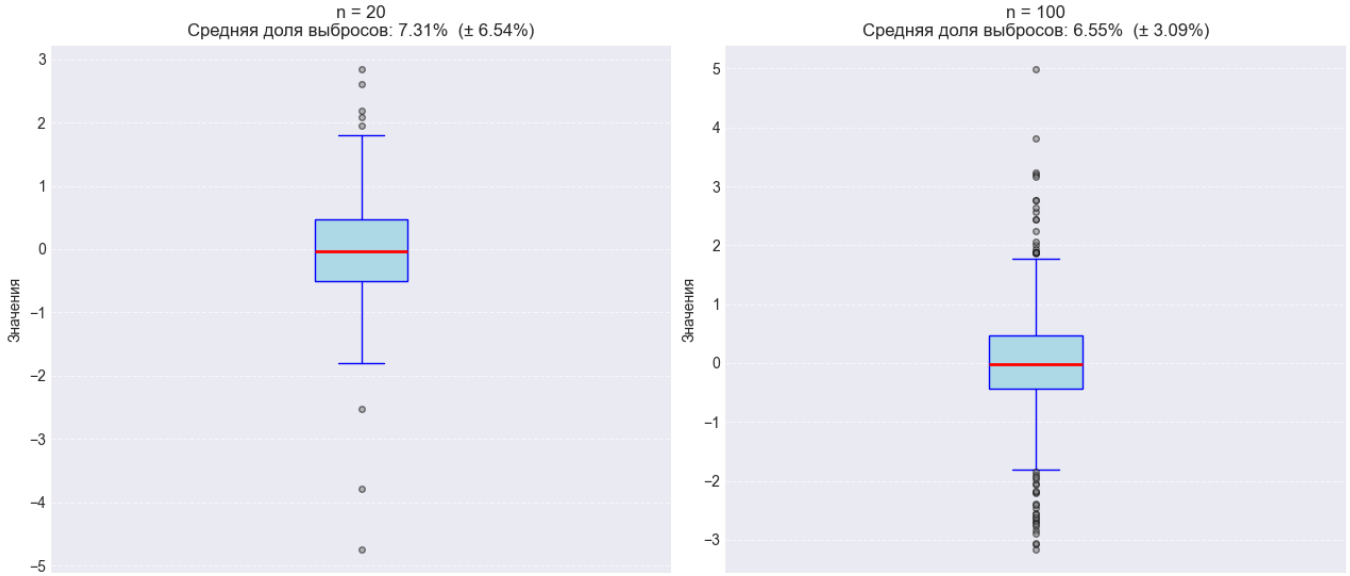

Распределение Нормальное

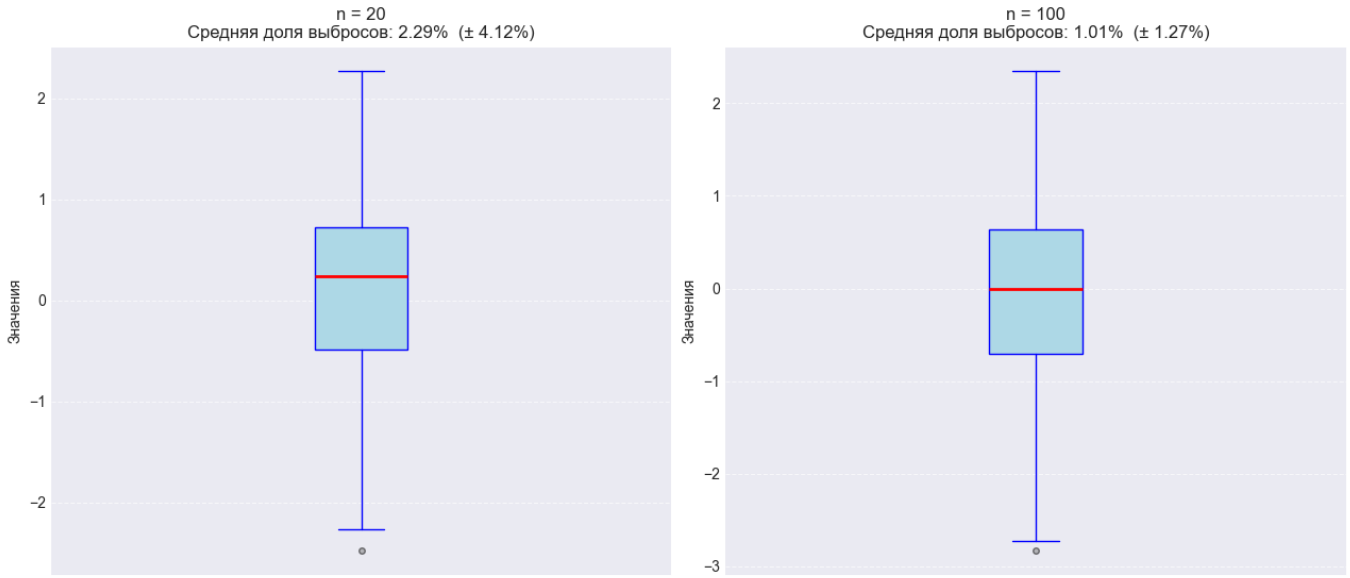

Распределение Пуассона

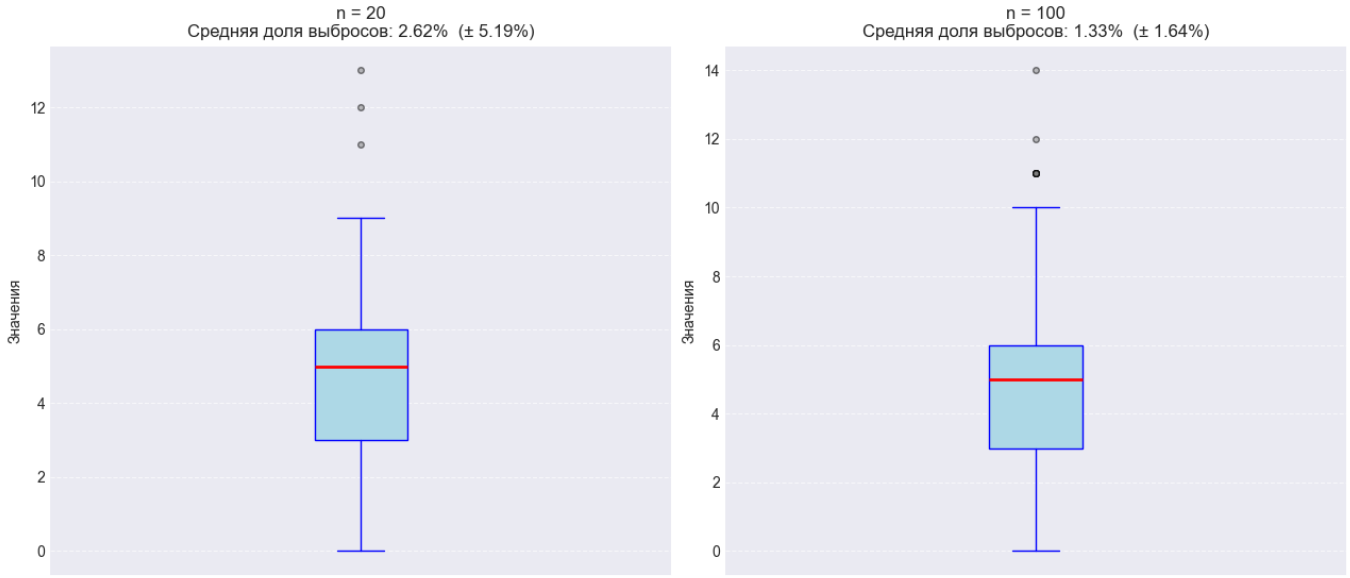

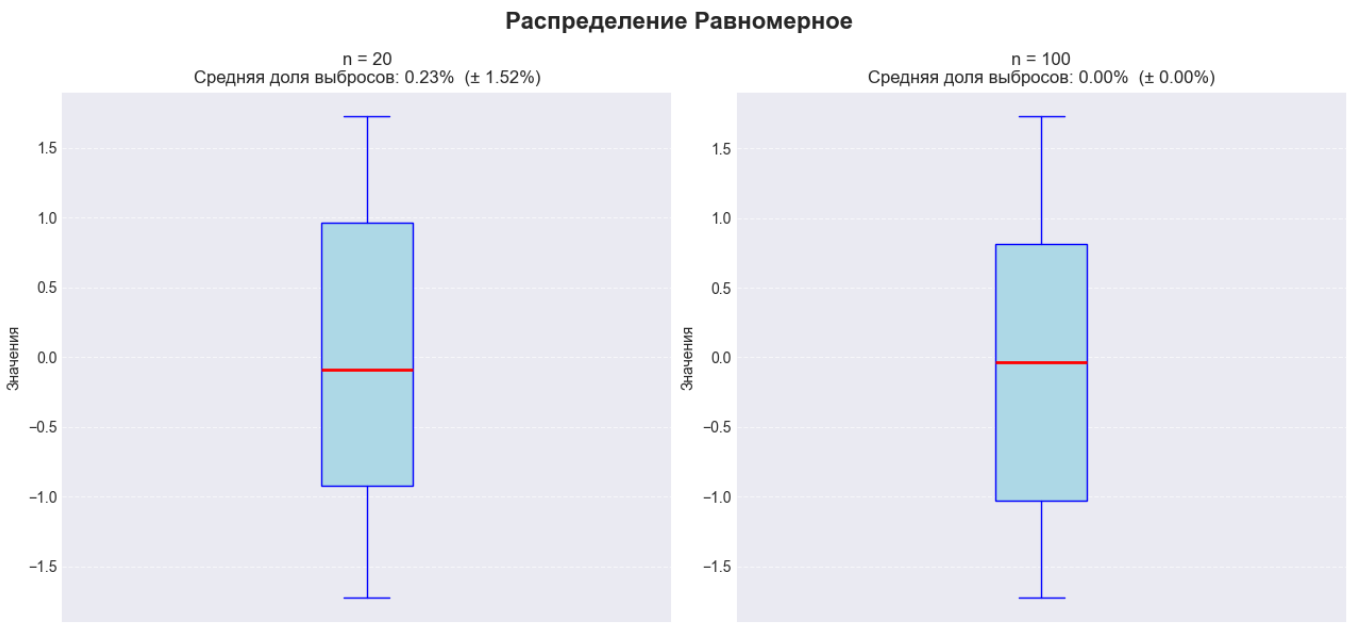
Распределение Равномерное
n = 20
Средняя доля выбросов: 0.23% (± 1.52%)
n = 100
Средняя доля выбросов: 0.00% (± 0.00%)
Значения
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5

Обсуждение

Увеличение объёма выборки с 20 до 100 по-разному сказывается на доле отсеиваемых аномальных значений для исследованных распределений:

Нормальное, Лапласа, Пуассона, Равномерное: средняя доля выбросов снижается (нормальное: 2.29% → 1.01%; Лапласа: 7.31% → 6.55%; Пуассона: 2.62% → 1.33%; равномерное: 0.23% → 0.00%). Одновременно стандартное отклонение уменьшается в 2–4 раза, что говорит о более стабильной и точной оценке при больших выборках.
Коши: доля выбросов остаётся практически неизменной (≈15.1–15.6%), хотя разброс результатов сокращается (σ с 7.06% до 3.35%). Это связано с тяжёлыми хвостами распределения, из-за которых число выбросов относительно объёма выборки не сокращается.

Таким образом, для распределений с лёгкими или умеренными хвостами увеличение n ведёт к снижению доли отсеиваемых выбросов и повышению устойчивости оценки. Для распределений с тяжёлыми хвостами (Коши) размер выборки практически не влияет на среднюю долю выбросов.

Выводы

В ходе лабораторной работы были построены боксплоты Тьюки, которые позволили наглядно оценить особенности каждого распределения. Экспериментально подтверждено, что доля выбросов зависит от формы распределения: минимальное значение наблюдается для равномерного закона (0%), максимальное – для распределения Коши (15%).
Промежуточное положение занимает распределение Лапласа (6–7%), что объясняется его более тяжёлыми по сравнению с нормальным, но не столь экстремальными хвостами, как у Коши.

Установлено также влияние объёма выборки: с ростом n от 20 до 100 вариативность оценки доли выбросов снижается для всех распределений. Для распределений с лёгкими хвостами (нормальное, равномерное, Пуассона) и для Лапласа сама доля выбросов уменьшается. Для распределения Коши доля выбросов остаётся практически неизменной.

Полученные результаты подтверждают практическую ценность боксплота как инструмента первичного анализа данных.