Санкт-Петербургский Политехнический Университет
Высшая школа прикладной математики и вычислительной физики, ФизМех
01.03.02 Прикладная математика и информатика

Отчет по лабораторной работе № 4
"Эмпирическая функция распределения и ядерные оценки плотности"

Выполнил студент гр. 5030102/30201 Елисеева М. А.
Преподаватель Баженов А. Н.

Санкт-Петербург
2025

Постановка задачи

Задание:
Сгенерировать выборки объёмом n = 20,60,100. Построить на них:
1. Эмпирическую функцию распределения (э. ф. р.) и теоретическую функцию распределения.
2. Ядерную оценку плотности (ядро — гауссово) и теоретическую плотность.
Выполнить 1-2 на отрезке [−4,4] для непрерывных распределений и на отрезке [6, 14] для распределения Пуассона.
Цели и задачи:
• Сделать вывод о том, как мощность выборки влияет на приближение эмпирической функции к истинной функции распределения.
• Сравнить два способа оценки плотности распределения: ядерные оценки и гистограммы.

Исследуются следующие распределения:
1. Нормальное N(x;0,1)
2. Коши C(x;0,1)
3. Лапласа L(x;0, 1/√2)
4. Пуассона P(k;10)
5. Равномерное U(x;−√3,√3)

Теоретическая часть

- Нормальное распределение

$$Normal(x, 0{,}1) = \frac{1}{\sqrt{2\pi}} e^{\frac{-x^2}{2}}$$

- Распределение Коши

$$Cauchy(x, 0{,}1) = \frac{1}{\pi} \frac{1}{x^2 + 1}$$

- Распределение Лапласса

$$Laplace\left(x, 0, \frac{1}{\sqrt{2}}\right) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}$$

- Распределение Пуассона

$$Poisson(k, 10) = \frac{10^k}{k!} e^{-10}$$

- Равномерное распределение

$$Uniform\left(x, -\sqrt{3}, \sqrt{3}\right) = \begin{cases} \frac{1}{2\sqrt{3}} \text{ при } |x| \leq \sqrt{3} \\ 0 \text{ при } |x| > \sqrt{3} \end{cases}$$

Пусть дана выборка независимых одинаково распределённых случайных величин $X_1, X_2, \dots, X_n$.
Эмпирическая функция распределения (э.ф.р.) определяется формулой:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}\{X_i \leq x\},$$

где $\mathbf{1}\{X_i \leq x\}$— индикаторная функция, равная 1, если $X_i \leq x$, и 0 в противном случае.
Эмпирическая функция распределения является **ступенчатой неубывающей функцией**, принимающей значения от 0 до 1.
Согласно теореме Гливенко–Кантелли, эмпирическая функция распределения сходится по вероятности к истинной функции распределения:

$$\sup_x \mid F_n(x) - F(x) \mid \xrightarrow[n\to\infty]{P} 0.$$

Это означает, что при увеличении объёма выборки эмпирическая функция всё точнее приближает теоретическую функцию распределения.

Ядерная оценка плотности распределения
Для получения более гладкой оценки используется ядерная оценка плотности, которая определяется формулой:

$$\hat{f}_n(x) = \frac{1}{nh}\sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right),$$

где

- $K(\cdot)$— ядерная функция,
- $h > 0$— параметр сглаживания (ширина окна).

В данной работе используется **гауссово ядро**:

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2}.$$

Ядерная оценка плотности является гладкой функцией, что позволяет лучше аппроксимировать истинную плотность распределения, особенно при небольших объёмах выборки.

Правило Сильвермана

Для практического выбора параметра сглаживания часто используется правило Сильвермана, которое минимизирует асимптотическую среднеквадратичную ошибку при предположении близости распределения к нормальному.

Параметр сглаживания вычисляется по формуле:

$$h = 1.06\,\sigma\, n^{-1/5},$$

где:

- σ— среднеквадратичное отклонение,
- n— объём выборки.

Робастная модификация правила Сильвермана

Для распределений с тяжёлыми хвостами (Коши) стандартное отклонение может быть неустойчивой характеристикой. В таких случаях используется робастная модификация правила Сильвермана, основанная на межквартильном размахе.

Параметр сглаживания определяется формулой:

$$h = 0.9 \cdot \min\left(\sigma, \frac{\mathrm{IQR}}{1.34}\right) \cdot n^{-1/5},$$

где:

- $\mathrm{IQR} = Q_3 - Q_1$— межквартильный размах,

Использование минимального значения между σи $\mathrm{IQR}/1.34$ позволяет снизить влияние выбросов и обеспечивает более устойчивую оценку плотности.

Влияние параметра сглаживания на оценку плотности

- При слишком малых значениях h ядерная оценка становится излишне неровной и отражает шум выборки.
- При слишком больших значениях h происходит чрезмерное сглаживание, что приводит к потере локальных особенностей распределения.

Реализация

Язык программирования: Python 3.12

Сторонние библиотеки:
numpy – генерация случайных выборок
matplotlib.pyplot – построение графиков
scipy.stats – теоретические распределения

Код: https://github.com/MaryEliseeva/matstat/blob/main/lab4/lab4.py

Результаты

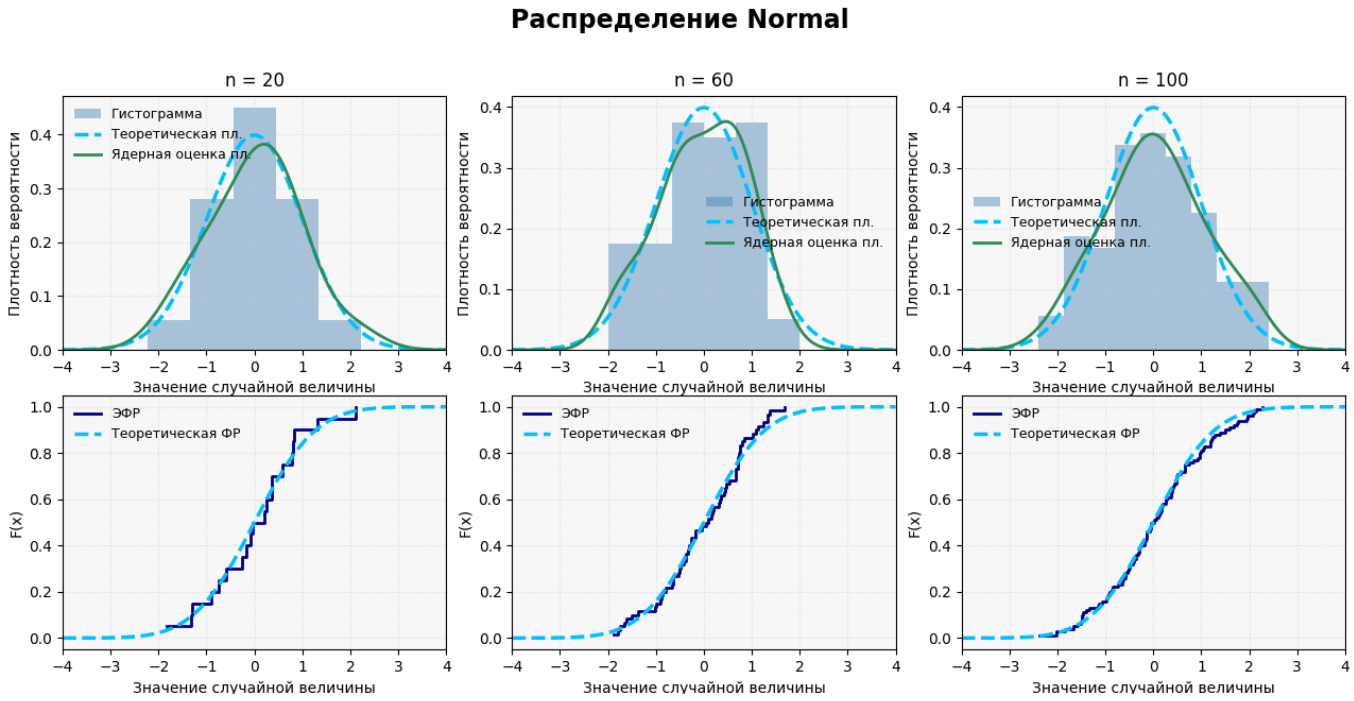
Распределение Normal
n = 20
n = 60
n = 100
Гистограмма
Теоретическая пл.
Ядерная оценка пл.
Плотность вероятности
Значение случайной величины
ЭФР
Теоретическая ФР
F(x)

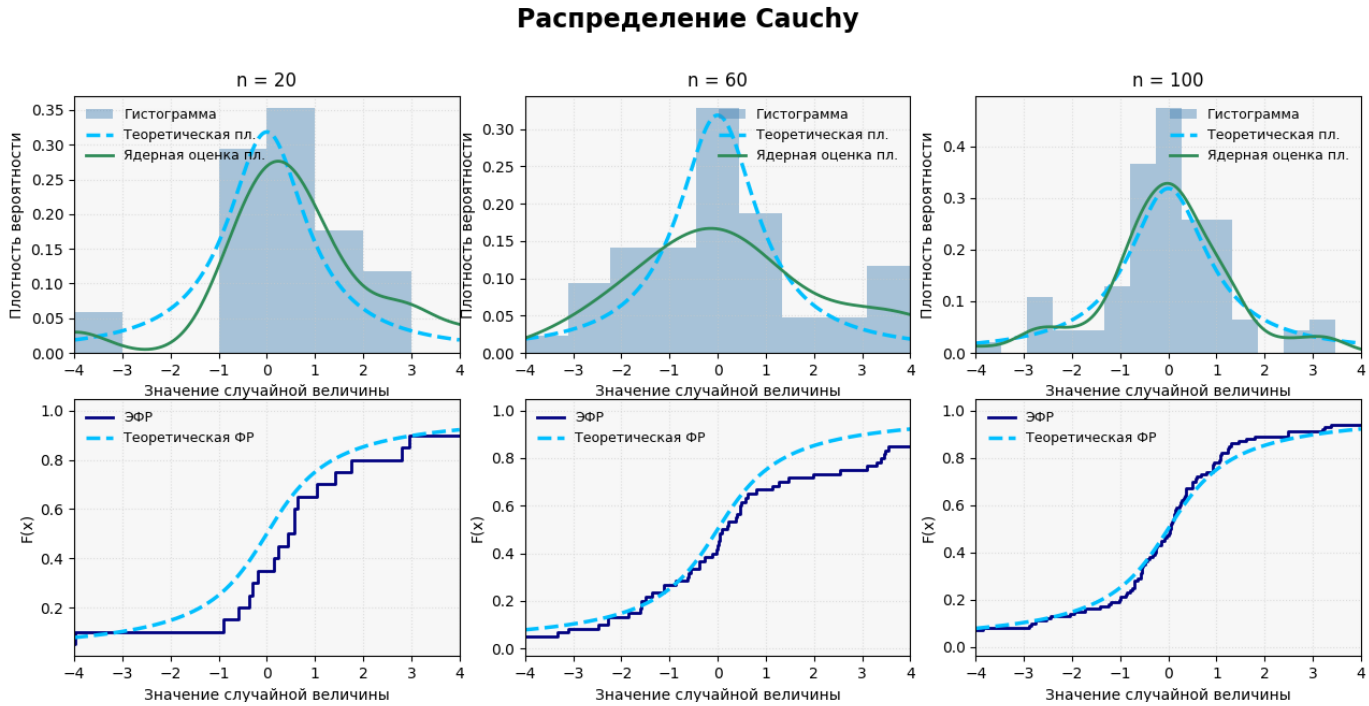
Распределение Cauchy
n = 20
n = 60
n = 100
Гистограмма
Теоретическая пл.
Ядерная оценка пл.
Плотность вероятности
Значение случайной величины
ЭФР
Теоретическая ФР
F(x)

Распределение Laplace

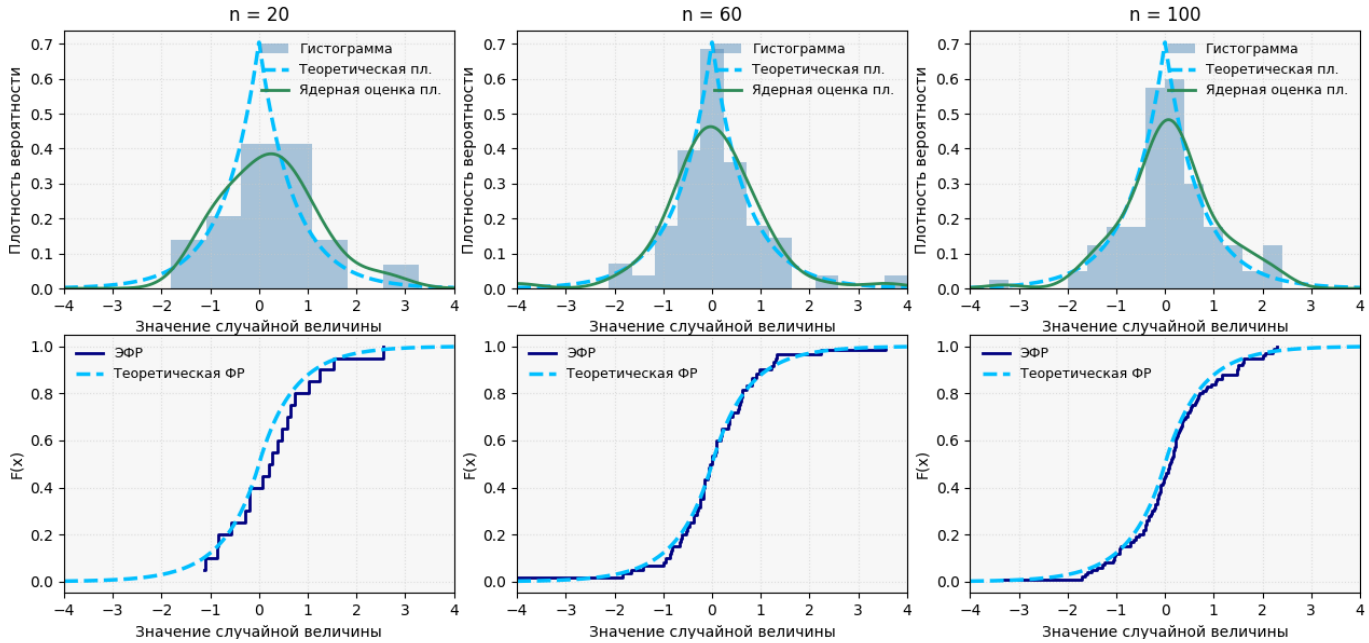

Распределение Poisson

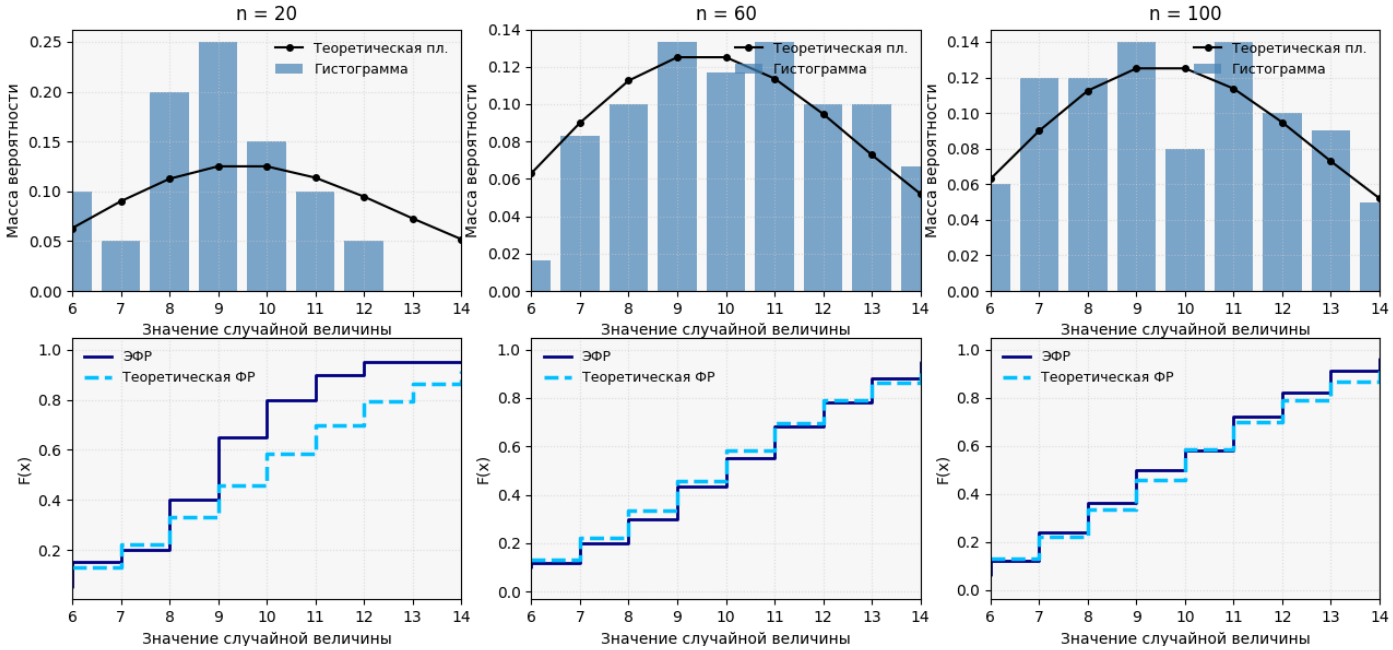

Распределение Uniform

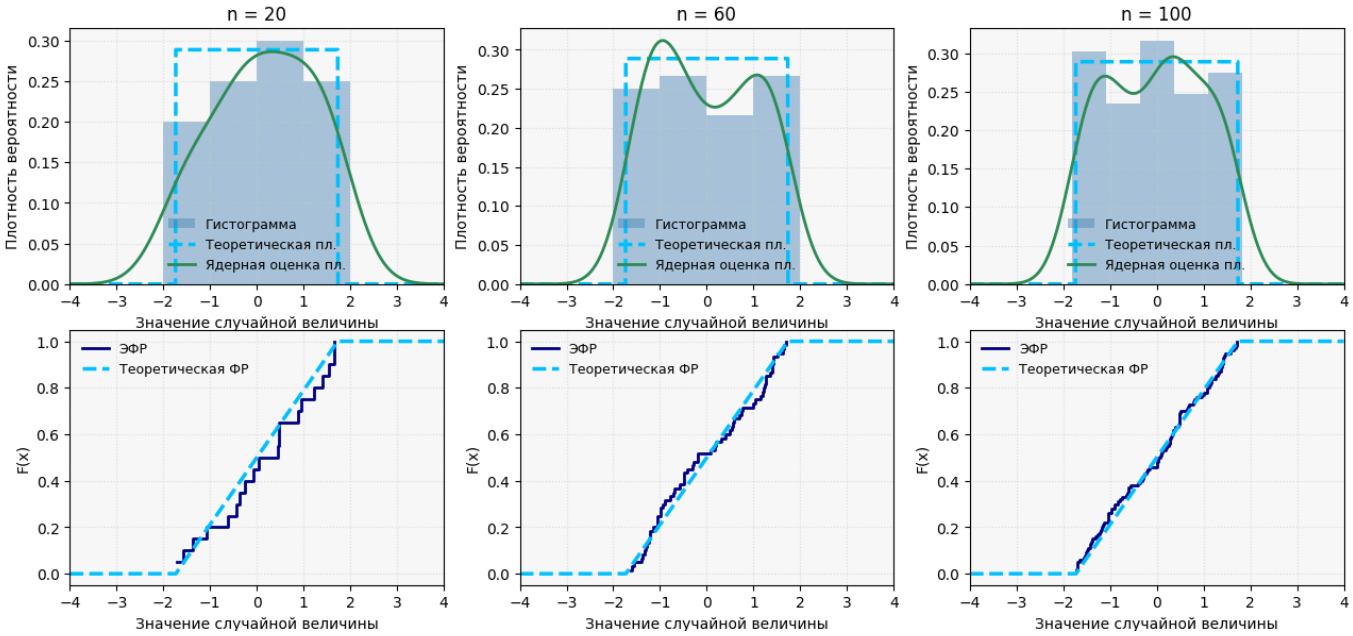

Обсуждение

В ходе лабораторной работы были исследованы свойства эмпирической функции распределения и различных оценок плотности вероятности на выборках разного объёма. По построенным графикам хорошо видно, как мощность выборки влияет на приближение эмпирической функции к истинной функции распределения.

Эмпирическая функция распределения представляет собой ступенчатую функцию, форма которой определяется объёмом выборки. При малом числе наблюдений ($n = 20$) ступени выражены резко, а отклонения от теоретической функции распределения заметны для всех рассмотренных распределений. Это связано с недостаточным числом данных для приближения истинной функции распределения.

С увеличением объёма выборки до $n = 60$ ступенчатость ЭФР сохраняется, однако расхождения с теоретической функцией становятся менее выраженными, а сама эмпирическая функция в среднем следует за теоретической кривой.

При $n = 100$ ЭФР для всех распределений, кроме Пуассона, практически совпадает с теоретической функцией распределения. Полученные результаты наглядно подтверждают теорему Гливенко–Кантелли о сходимости эмпирической функции распределения к истинной функции распределения по вероятности при увеличении объёма выборки.

При анализе плотностей распределения отчётливо проявляется различие между гистограммной оценкой и ядерным сглаживанием. Гистограмма является ступенчатой функцией и существенно зависит от выбора числа интервалов. При малых объёмах выборки она имеет неровный вид и может искажать форму истинной плотности. При увеличении числа наблюдений гистограмма начинает лучше аппроксимировать плотность.

Ядерная оценка плотности с гауссовым ядром позволяет получить более гладкую аппроксимацию плотности распределения. Для непрерывных распределений она лучше отражает общую форму теоретической плотности уже при умеренных объёмах выборки. В то же время для равномерного распределения ядерное сглаживание приводит к сглаживанию резких границ плотности, что хорошо демонстрирует отличие этого подхода от гистограммной оценки.

Таким образом, проведённые эксперименты наглядно демонстрируют, что увеличение объёма выборки улучшает качество как эмпирической функции распределения, так и оценок плотности. Ядерное сглаживание позволяет получить более гладкие и информативные оценки плотности по сравнению с гистограммой, однако при малых выборках и для распределений с тяжёлыми хвостами все оценки остаются чувствительными к случайным колебаниям данных.

Выводы

1. С ростом объёма выборки эмпирическая функция распределения точнее приближает теоретическую, но для распределений с тяжёлыми хвостами (Коши) даже 100 наблюдений недостаточно для устойчивости.
2. Гистограмма даёт ступенчатую оценку, хорошо работающую при больших выборках или для дискретных распределений; ядерная оценка плотности более гладкая и точная, особенно при малых выборках, и лучше воспроизводит истинную форму распределения.