

Санкт-Петербургский Политехнический Университет
Высшая школа прикладной математики и вычислительной физики, ФизМех
01.03.02 Прикладная математика и информатика

Отчет по лабораторной работе № 5
"Корреляционный анализ и эллипсы рассеивания"

Выполнил студент гр. 5030102/30201
Преподаватель

Елисеева М. А.
Баженков А. Н.

Постановка задачи

Задание: Сгенерировать двумерные выборки (x, y) объемом $n = 20, 60, 100$ из:

- Двумерного нормального распределения $N(0,0,1,1, \rho)$, где $\rho = 0, 0.5, 0.9$
- Смеси $0.9 N(0,0,1,1, 0.9) + 0.1 N(0,0,10,10, -0.9)$.

Для каждой выборки:

1. Вычислить коэффициенты корреляции Пирсона, Спирмена и квадратный. Повторить 1000 раз, найти средние и дисперсии
2. Построить диаграммы рассеяния и эллипсы равновероятности.

Цели и задачи:

- Сравнить исходное значение коэффициента корреляции с вычисленными.
- Изучить способы визуализации ковариационной структуры данных.

Теоретическая часть

- Двумерное нормальное распределение

$$N(x, y, \bar{x}, \bar{y}, \sigma_x, \sigma_y, \rho) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)}\left(\frac{(x-\bar{x})^2}{\sigma_x^2} - 2\frac{(x-\bar{x})(y-\bar{y})}{\sigma_x\sigma_y} + \frac{(y-\bar{y})^2}{\sigma_y^2}\right)\right)$$

- Корреляционный момент(ковариация)

$$K = cov(X, Y) = M[(X - \bar{x})(Y - \bar{y})]$$

- Коэффициент корреляции

$$\rho = \frac{K}{\sigma_x \sigma_y}$$

- Выборочный коэффициент корреляции Пирсона

$$r = \frac{\frac{1}{n}\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n}\sum(x_i - \bar{x})^2 \frac{1}{n}\sum(y_i - \bar{y})^2}} = \frac{K}{s_x s_y}$$

- Выборочный коэффициент ранговой корреляции Спирмена

$$r_s = \frac{\frac{1}{n}\sum(u_i - \bar{u})(v_i - \bar{v})}{\sqrt{\frac{1}{n}\sum(u_i - \bar{u})^2 \frac{1}{n}\sum(v_i - \bar{v})^2}}$$

- Выборочный квадратный коэффициент корреляции

$$r_Q = \frac{(n_1 + n_3) - (n_2 + n_4)}{n}$$

Реализация

Язык программирования: Python 3.14

Сторонние библиотеки:

`numpy` – генерация случайных выборок

`matplotlib.pyplot` – построение графиков

`scipy.stats` – теоретические распределения

Код: <https://github.com/MaryEliseeva/matstat/blob/main/lab5/lab5.py>

Результаты


r Пирсон

rs Спирмен


rq Квадрантный

Двумерное нормальное распределение $N(0,0,1,1,\rho)$


n=20, $\rho=0$
 $r=-0.05$, $rs=-0.11$, $rq=-0.40$




n=20, $\rho=0.5$
 $r=0.61$, $rs=0.64$, $rq=0.60$




n=20, $\rho=0.9$
 $r=0.93$, $rs=0.85$, $rq=0.80$




n=60, $\rho=0$
 $r=-0.04$, $rs=-0.03$, $rq=0.00$




n=60, $\rho=0.5$
 $r=0.38$, $rs=0.37$, $rq=0.27$




n=60, $\rho=0.9$
 $r=0.85$, $rs=0.84$, $rq=0.87$




n=100, $\rho=0$
 $r=0.08$, $rs=0.11$, $rq=0.12$



n=100, $\rho=0.5$
 $r=0.56$, $rs=0.52$, $rq=0.24$




n=100, $\rho=0.9$
 $r=0.92$, $rs=0.91$, $rq=0.80$




Смесь распределений


mixture, n=20
 $r=-0.82$, $rs=0.16$, $rq=0.40$



mixture, n=60
 $r=-0.82$, $rs=0.43$, $rq=0.40$



mixture, n=100
 $r=-0.71$, $rs=0.47$, $rq=0.52$



Двумерное нормальное распределение

n	ρ	Пирсон (ср.)	Пирсон (дисп.)	Спирмен (ср.)	Спирмен (дисп.)	Квадрантный (ср.)	Квадрантный (дисп.)
20	0	0.0026	0.0533	0.0044	0.0540	-0.0006	0.0521
60	0	-0.0019	0.0173	-0.0024	0.0176	-0.0049	0.0178
100	0	0.0009	0.0103	0.0011	0.0104	0.0044	0.0110
20	0.5	0.4791	0.0343	0.4465	0.0378	0.3038	0.0486
60	0.5	0.4973	0.0098	0.4751	0.0112	0.3303	0.0153
100	0.5	0.4966	0.0058	0.4777	0.0066	0.3301	0.0094
20	0.9	0.8933	0.0027	0.8639	0.0050	0.7014	0.0279
60	0.9	0.8975	0.0007	0.8818	0.0012	0.6999	0.0081
100	0.9	0.8990	0.0004	0.8856	0.0006	0.7096	0.0050

Смесь распределений

n	Пирсон (ср.)	Пирсон (дисп.)	Спирмен (ср.)	Спирмен (дисп.)	Квадрантный (ср.)	Квадрантный (дисп.)
20	-0.3646	0.4096	0.4666	0.0745	0.5270	0.0370
60	-0.6212	0.0912	0.4833	0.0270	0.5607	0.0122
100	-0.6886	0.0335	0.4741	0.0158	0.5632	0.0071

Обсуждение

Двумерное нормальное распределение

1. При $\rho = 0$ на всех графиках наблюдается хаотичное расположение точек без выраженной направленности, эллипсы близки к окружностям. Выборочные коэффициенты корреляции r, r_s, r_q колеблются около нуля. При увеличении объёма выборки ($n = 60, 100$) облако становится более плотным и симметричным, а разброс коэффициентов уменьшается, что подтверждается снижением дисперсий.
2. При $\rho = 0.5$ на графиках появляется чётко выраженная положительная линейная зависимость: точки вытягиваются вдоль диагонали, эллипс наклонён. Значения коэффициента Пирсона на графиках близки к табличным средним и к теоретическому значению. Коэффициент Спирмена немного ниже, но также хорошо отражает зависимость. Квадрантный коэффициент заметно меньше и более вариативен.
3. При $\rho = 0.9$ наблюдается сильная линейная зависимость: точки практически лежат вдоль прямой, эллипс сильно вытянут. Коэффициент Пирсона на графиках близок к 0.9, что совпадает с табличными средними значениями. Спирмен также близок, но немного ниже, а квадрантный коэффициент остаётся меньше, что связано с потерей информации при его вычислении. С ростом n разброс значений уменьшается, что видно и визуально, и по уменьшению дисперсий.

при увеличении n оценки стабилизируются, а коэффициент Пирсона лучше всего отражает линейную зависимость.

Смесь распределений

1. На графиках чётко видно, что данные состоят из двух частей: основное плотное облако с положительной зависимостью и редкие выбросы с сильной отрицательной корреляцией. Из-за этого распределение не является нормальным, и эллипс лишь приближённо описывает общую структуру.
2. Коэффициент Пирсона на графиках принимает отрицательные значения (например, около $-0.82, -0.71$), что согласуется с табличными средними и отражает влияние выбросов с большой дисперсией. При увеличении n значение стабилизируется и приближается к теоретическому значению смеси.
3. Коэффициенты Спирмена и квадрантный на графиках остаются положительными, несмотря на отрицательный коэффициент Пирсона. Это связано с тем, что они учитывают ранги и расположение точек относительно медиан, а основная масса точек имеет положительную зависимость. Табличные значения подтверждают эту устойчивость: они остаются положительными и слабо меняются при увеличении n .

Для смеси распределений разные коэффициенты корреляции дают принципиально разные результаты.

Полученные результаты подтверждают, что выбор метода оценки корреляции зависит от структуры данных и наличия выбросов

Выводы

- Для двумерного нормального распределения вычисленные коэффициенты корреляции хорошо согласуются с теоретическим значением ρ . Коэффициент Пирсона наиболее точно приближает заданную линейную зависимость, особенно при увеличении объёма выборки. Коэффициенты Спирмена и квадрантный дают близкие, но несколько заниженные оценки.
- В случае смеси распределений наблюдается существенное расхождение между коэффициентами: коэффициент Пирсона принимает отрицательные значения и приближается к теоретической корреляции смеси, тогда как коэффициенты Спирмена и квадрантный остаются положительными. Это связано с тем, что Пирсон чувствителен к выбросам, а остальные коэффициенты отражают структуру основной массы данных.
- С увеличением объёма выборки оценки всех коэффициентов становятся более стабильными, что подтверждается уменьшением их дисперсий и меньшим разбросом значений на графиках.
- Диаграммы рассеяния и эллипсы равновероятности эффективно визуализируют структуру нормального распределения: при увеличении ρ эллипс вытягивается вдоль направления зависимости. Однако для смеси распределений эллипс даёт лишь приближённое представление и не отражает сложную структуру данных с выбросами.