

Санкт-Петербургский Политехнический Университет
Высшая школа прикладной математики и вычислительной физики, ФизМех
01.03.02 Прикладная математика и информатика

Отчет по лабораторной работе № 6
"Линейная регрессия. Метод наименьших квадратов и
наименьших модулей"

Выполнил студент гр. 5030102/30201
Преподаватель

Елисеева М. А.
Баженов А. Н.

Постановка задачи

Задание:

1. Задать равномерные значения x_i на отрезке $[-1.8, 2]$ с шагом 0.2 (20 точек).
2. Сгенерировать $y_i = 2 + 2x_i + \varepsilon_i$, где $\varepsilon_i \sim N(0, 1)$.
3. Оценить параметры a, b двумя методами:
 - Метод наименьших квадратов (МНК).
 - Метод наименьших модулей (МНМ).
4. Повторить пункты 1–3, добавив выбросы: $y_1 \leftarrow y_1 + 10, y_{20} \leftarrow y_{20} - 10$.

Цели и задачи:

- Сравнить устойчивость МНК и МНМ к выбросам.
- Построить графики регрессионных прямых и исходных данных.

Теоретическая часть

1. Модель простой линейной регрессии

Простая линейная регрессия представляет собой модель описания данных, в которой связь между переменными выражается уравнением:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, i = 1, \dots, n$$

где:

- x_i — заданные значения фактора;
- y_i — наблюдаемые значения отклика;
- β_0, β_1 — **неизвестные параметры**, подлежащие оцениванию;
- ε_i — независимые, нормально распределенные случайные величины $N(0, \sigma)$ с нулевым математическим ожиданием и одинаковой дисперсией.

В данной модели предполагается, что весь разброс экспериментальных точек обусловлен только погрешностями измерения отклика y , в то время как погрешностями фактора x можно пренебречь.

2. Метод наименьших квадратов (МНК)

Наиболее распространенным методом оценивания параметров является **метод наименьших квадратов**. Его суть заключается в минимизации суммы квадратов остатков (рассогласования):

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \rightarrow \min_{\beta_0, \beta_1}$$

Оценки, реализующие этот минимум, называются **МНК-оценками**. Критерием оптимальности в данном случае выступает **l2-норма**.

Расчетные формулы для МНК-оценок:

Для нахождения оценок используются условия экстремума (равенство нулю частных производных), что приводит к системе нормальных уравнений. В результате получаются следующие формулы:

- **Коэффициент наклона:**

$$\hat{\beta}_1 = \frac{\bar{x}\bar{y} - \bar{x}\bar{y}}{\bar{x}^2 - (\bar{x})^2}$$

- **Свободный член:**

$$\hat{\beta}_0 = \bar{y} - \bar{x}\hat{\beta}_1$$

где $\bar{x}\bar{y}$ — выборочная ковариация, $\bar{x}^2$ — средний квадрат x , $\bar{x}, \bar{y}$ — выборочные средние.

3. Робастные оценки и метод наименьших модулей (МНМ)

Классический МНК чувствителен к наличию выбросов. Для обеспечения **робастности** (устойчивости) оценок используется **метод наименьших модулей**, который минимизирует сумму абсолютных отклонений:

$$\sum_{i=1}^n |y_i - \beta_0 - \beta_1 x_i| \rightarrow \min_{\beta_0, \beta_1}$$

Этот метод минимизирует **l1-норму** разности между экспериментальными данными и значениями функции. Робастность МНМ объясняется тем, что он опирается на свойства медианы, которая менее чувствительна к экстремальным значениям на концах ряда, чем среднее арифметическое.

В отличие от МНК, для которого есть простые аналитические формулы, задача МНМ на практике решается с помощью численных методов. Чтобы не прибегать к сложным численным методам используем простейшую альтернативу для расчета робастных оценок коэффициентов, используя следующие формулы

- Вместо выборочных средних используются **выборочные медианы** ($\text{med } x$ и $\text{med } y$).
- Вместо среднеквадратических отклонений — полумежквартильные размахи q_y^* , $q_x^* = \text{IQR}_x / 2$
- Вместо коэффициента корреляции Пирсона — **знаковый (квадрантный) коэффициент корреляции** r_Q

Коэффициент знаковой корреляции

Сначала вычисляется коэффициент знаковой корреляции между переменными x и y :

$$r_Q = \frac{1}{n} \sum_{i=1}^n \text{sgn}(x_i - \text{med } x) \cdot \text{sgn}(y_i - \text{med } y),$$

Оценка коэффициента наклона

$$\hat{\beta}_1^R = r_Q \cdot \frac{q_y^*}{q_x^*}.$$

Оценка свободного члена

$$\hat{\beta}_0^R = \text{med } y - \hat{\beta}_1^R \cdot \text{med } x.$$

4. Оценка качества регрессии

Для количественной оценки точности полученных моделей в лабораторной работе используется **относительная погрешность** параметров:

$$\delta z = \frac{|\hat{z} - z|}{z} \cdot 100\%$$

где z — истинное значение параметра, а $\hat{z}$ — его приближенная оценка.

Реализация

Язык программирования: Python 3.14

Сторонние библиотеки:



`numpy` — генерация случайных выборок

`matplotlib.pyplot` — построение графиков

`scipy.stats` — теоретические распределения

Код: <https://github.com/MaryEliseeva/matstat/blob/main/la65/lab6.py>

Результаты



Без выбросов

Метод	a	Δa	$\delta a, \%$	b	Δb	$\delta b, \%$
МНК	1.878	0.122	6.08	1.502	0.498	24.89
МНМ	1.706	0.294	14.68	1.561	0.439	21.95

С выбросами

Метод	a	Δa	$\delta a, \%$	b	Δb	$\delta b, \%$
МНК	2.021	0.021	1.07	0.074	1.926	96.32
МНМ	1.817	0.183	9.13	1.407	0.593	29.65

Обсуждение

1. Анализ данных без выбросов

На графике «Без выбросов» все экспериментальные точки располагаются вдоль истинной прямой $y = 2 + 2x$ с небольшим случайным разбросом, что соответствует модели. Прямые, построенные по МНК и МНМ, визуально практически не отличаются от эталонной линии и проходят через облако данных. Численные оценки подтверждают это: относительная погрешность для коэффициента a составила 6,08 % (МНК) и 14,68 % (МНМ); для коэффициента b – 24,89 % (МНК) и 21,95 % (МНМ). Таким образом, в отсутствие аномальных наблюдений оба метода адекватно восстанавливают зависимость.

2. Анализ данных с выбросами

При внесении выбросов поведение методов кардинально различается. На графике «С выбросами» видно, что прямая МНК (пунктир) резко изменила наклон, став почти горизонтальной. Это связано с тем, что квадратичная функция потерь МНК сильно штрафует большие отклонения, и модель «подстраивается» под аномальные точки, жертвуя общей тенденцией. Напротив, прямая МНМ (сплошная линия) сохранила наклон, близкий к истинному, и проходит через основную массу данных, игнорируя выбросы. Этот визуальный вывод подтверждается таблицей численных результатов.

Для МНК погрешность оценки наклона b достигла 96,32 %, что свидетельствует о практически полной потере информации о связи между x и y . Свободный член a при этом оценивается с малой погрешностью (1,07 %), что объясняется тем, что выбросы расположены симметрично по краям диапазона и в сумме почти не смещают положение прямой на уровне центральной области данных. Однако это не означает адекватности модели: при столь сильном искажении наклона оценка свободного члена теряет содержательный смысл. Для МНМ погрешность b составила 29,65%, что более чем в три раза меньше, чем у МНК, а погрешность a – 9,13 %. Это демонстрирует устойчивость метода наименьших модулей к выбросам.

3. Сравнение устойчивости методов

Полученные результаты наглядно иллюстрируют фундаментальное различие между МНК и МНМ. МНК, будучи оптимальным при нормальном распределении ошибок, крайне чувствителен к выбросам: даже два аномальных наблюдения на краях диапазона приводят к катастрофическому искажению модели. МНМ, основанный на минимизации суммы абсолютных отклонений (l_1 -норма), устойчив к выбросам, так как опирается на медиану, которая менее чувствительна к экстремальным значениям. Это свойство делает МНМ предпочтительным при анализе реальных данных, где аномалии встречаются часто.

Выводы

Метод наименьших модулей обладает робастностью, в то время как классический метод наименьших квадратов теряет надёжность в присутствии выбросов. Визуальное сравнение регрессионных прямых и количественный анализ относительных погрешностей однозначно свидетельствуют в пользу применения робастных методов при обработке данных, содержащих аномальные наблюдения. В отсутствие выбросов оба метода показывают сопоставимые результаты, что соответствует теоретическим представлениям.